

《大数据应用分析实践》项目指南

项目名称：葡萄酒质量数据分析与建模实践

一、项目背景与目标

本项目基于经典的 Wine Quality dataset 数据集展开。数据包含红葡萄酒与白葡萄酒的理化指标以及对应的质量评分。实际问题中，葡萄酒质量往往通过化学分析与人工品评共同确定，本项目的目标是借助数据分析方法，探索理化指标与质量之间的关系，并尝试建立模型进行预测或识别。

本项目要求你完成一个完整的数据科学实践流程。从数据读取与理解开始，经过数据清洗、探索性分析、任务设计、建模与评估，最终形成对数据和问题的系统性认识。项目不仅关注模型结果，更强调分析过程和结果解释。你需要能够说明的问题包括：数据有什么特征？为什么选择某种方法？模型结果说明了什么？等等。

完成本项目后，你应能够独立完成一个基础的数据分析项目，并具备初步的数据建模与解释能力。

中英文翻译对照：Wine: 葡萄酒；Red wine: 红葡萄酒；White wine: 白葡萄酒

二、实践工具和软件

建议同学们使用统一的软件环境完成实践任务，以减少运行错误。推荐配置如下：

Python	Python 3.9 及以上版本
开发环境	Jupyter Notebook 或 JupyterLab
推荐发行版	Anaconda（推荐，便于安装依赖与管理环境）
常用库	scikit-learn、Pandas、NumPy、matplotlib/Seaborn

三、数据集说明

本项目使用以下数据文件：

- winequality-red.csv（红葡萄酒，1599 条）

- winequality-white.csv (白葡萄酒, 4898 条)
- winequality.names (数据说明文件)

两个数据文件结构一致, 均包含 11 个理化指标和 1 个质量评分变量。你需要将两个数据集合并, 可以新增变量 type 表示葡萄酒类型 (红葡萄酒或白葡萄酒), 以支持后续对比分析。

需要特别注意以下数据特点: 该数据集不存在缺失值, 但仍需通过代码验证; 质量评分 quality 虽为整数, 但分布不均衡, 主要集中在 5、6、7 三个分数上; 所有变量均为数值型, 适合进行回归、分类、聚类 and 降维分析; 红酒与白酒在多个指标上可能存在显著差异, 这一点应在分析中重点体现。

四、项目任务说明

本项目的任务按照数据科学流程展开, 各阶段之间存在明确的逻辑关系。你需要按顺序完成各部分内容, 并在报告中体现这一过程。

第一部分：数据读取与初步理解

你需要分别读取 red wine 与 white wine 数据文件, 并确认两者字段结构一致。在此基础上, 为数据新增 type 变量, 并完成合并, 得到一个统一的数据集。

完成后, 应对数据进行初步理解, 包括数据规模、变量类型、字段含义以及不同类型葡萄酒的样本数量分布。同时, 应查看质量评分的分布情况, 判断是否存在明显集中或不均衡现象。

这一部分的重点在于建立对数据整体结构的认识, 而不是简单导入数据。报告中应使用简洁文字说明数据的基本情况, 而不是重复代码输出。

第二部分：数据预处理

在这一阶段, 你需要对数据进行质量检查和必要处理。首先, 应验证数据是否存在缺失值, 并明确说明结果。其次, 需要检查是否存在重复记录, 并决定是否删除。第三, 应通过统计方法或可视化方式识别异常值, 并说明处理策略。

此外, 需要检查各变量的数据类型, 并根据建模需求进行必要转换。在后续使用基于距离或梯度的方法 (如 KNN、SVM、逻辑回归) 时, 通常需要对数据进行标准化处理。你需要明确说明是否进行了标准化, 以及为什么需要这样做。

这一部分的关键不在于做了什么操作, 而在于为什么这样做, 需要把原因讲清楚。

第三部分：探索性数据分析 (EDA)

你需要通过统计分析与可视化方法，对数据进行系统探索。分析应围绕三个核心问题展开：

第一，整体分布。你需要分析各理化指标的分布特征，包括均值、离散程度以及是否存在偏态或极端值。

第二，红酒与白酒的差异。你需要比较红葡萄酒与白葡萄酒在主要理化指标上的分布差异，例如酒精度、酸度、残糖、二氧化硫等，并说明哪些变量最能区分两类葡萄酒。

第三，质量差异。你需要分析不同质量水平的葡萄酒在各变量上的表现差异，并思考哪些变量可能对质量有较大影响。

在此基础上，应进行变量之间的关系分析，例如绘制相关性热力图，观察变量之间以及变量与质量之间的关系。

本部分至少需要包含若干具有解释价值的图表，每一张图都必须配有文字说明，明确指出图中反映的现象及其意义。

第四部分：分析任务设计

在完成数据探索之后，你需要明确本项目的建模目标，即：你打算解决什么问题。这是本项目的关键步骤之一。

结合数据特点，本项目允许以下三类任务：

第一类是回归任务，将 quality 作为连续变量进行预测；

第二类是分类任务，将 quality 转换为类别变量，例如高质量与普通质量，或低、中、高三类；

第三类是聚类任务，不使用质量标签，仅根据理化指标对葡萄酒进行分组分析。

你必须至少选择三类任务中的两类，并说明任务设计理由。

第五部分：PCA 降维分析

你需要使用 PCA 对数据进行降维分析，并将数据投影到二维空间进行可视化。图中可以使用不同颜色表示葡萄酒类型或质量等级。在完成可视化之后，需要解释降维结果。例如，红葡萄酒与白葡萄酒是否能够分离，不同质量等级是否存在聚集趋势，以及前两个主成分保留了多少信息。

这一部分的重点在于利用降维帮助理解数据结构，而不是仅仅完成计算过程。

第六部分：建模与分析任务实现（核心部分）

这一部分是本项目的重点。你需要基于前面设计的任务，完成模型建立、预测与分析。对于本数据集，可以开展以下几种典型任务，你需要选择其中至少两类任务，并完成完整流程。

如果选择回归任务，你需要以 quality 为目标变量，建立回归模型预测其数值。可以先建立一个线性回归模型作为基线，再尝试非线性模型（如随机森林或支持向量回归）进行比较。完成模型训练后，应使用合适的指标（如 MAE、RMSE、 R^2 ）评估模型表现，并分析误差情况。例如，模型在哪些样本上误差较大，是否对高质量或低质量样本预测较困难，以及不同模型之间的差异。

如果选择分类任务，你需要先对 quality 进行合理分组。例如，可以将质量评分较高的样本定义为“高质量”，其余为“普通质量”，或划分为低、中、高三类。随后建立分类模型，例如逻辑回归、KNN、SVM 或随机森林。模型训练完成后，需要使用准确率、精确率、召回率、F1 值以及混淆矩阵进行评估，并分析模型的错误分类情况。例如，模型是否容易混淆相邻质量等级，是否存在类别不均衡影响结果等问题。

如果完成聚类任务，你需要在不使用质量标签的情况下，对数据进行聚类分析。可以使用 K-Means 或层次聚类方法，并结合 PCA 可视化结果。聚类完成后，需要分析各簇的特征，以及这些簇是否与葡萄酒类型或质量水平存在一定对应关系。

你还应考虑以下问题：是否使用 type 变量作为特征；是否将红葡萄酒与白葡萄酒分开建模；不同建模策略是否会影响结果。你需要对这些问题进行实验和讨论。

第七部分：模型比较

在完成模型训练后，你需要对结果进行系统比较。比较不仅限于指标大小，还应包括模型的稳定性、可解释性以及适用性。如果进行了多个模型实验，应比较它们的表现差异，并说明哪个模型更适合当前任务以及原因。如果同时完成了回归和分类任务，也可以比较这两种任务形式的优缺点。

重点在于回答：模型结果是否可靠，是否具有实际意义，以及是否能够支持你在前面提出的问题。

第八部分：综合结论

在项目最后，你需要对整个分析过程进行总结。结论部分应回答以下问题：红葡萄酒与白葡萄酒在理化特征上有哪些主要差异；哪些变量与葡萄酒质量关系最明显；所建立的模型是否能够有效预测或识别质量；本数据集存在哪些局限，例如缺少产地、价格或品种信息；如果继续改进该项目，还可以从哪些方面进行优化。

这一部分应以总结和提炼为主，而不是重复前文内容。

五、阶段任务与过程控制

本实践课程共计 4 周时间 **(5 月 11 日-6 月 5 日)**，要求同学们每周工作不低于 8 小时。为了保证项目按计划推进，本项目设置三个阶段性提交任务。阶段提交不作为最终成果替代，但将作为过程评估的重要依据。阶段提交不要求完美结果，但要求过程真实、思路清晰、能够体现项目推进情况。

在第一周结束时 (5 月 17 日)，你需要提交第一阶段成果。成果应包括对数据的理解、数据预处理过程以及初步的探索性分析结果，对应“四、项目任务说明”中的第 1、2、3 部分。你需要说明数据结构，验证是否存在缺失值，说明异常值及其处理方式，并展示若干关键图表，同时给出初步分析结论，例如哪些变量可能影响质量、红酒与白酒的主要差异等。本阶段的目标是确保你已经完成对数据的基本理解和分析准备，而不是停留在简单读取数据的阶段。

在第二周结束时 (5 月 24 日)，你需要提交第二阶段成果。成果应包括你所选择的分析任务，即回归任务或分类任务，并说明选择该任务的理由；同时需要明确建模目标、因变量与自变量的设定、初步建模方案以及特征选择思路，对应“四、项目任务说明”中的第 4、5 部分。你需要说明为什么将葡萄酒质量预测设计为回归问题或分类问题，准备使用哪些特征进行建模，是否需要特征进行标准化、编码或筛选，并初步说明计划尝试的模型。本阶段的目标是确保你已经从探索性分析进入任务设计与建模准备阶段，能够清楚说明“要解决什么问题、为什么这样设计、准备用什么方法解决”。

在第三周结束时 (5 月 31 日)，你需要提交第三阶段成果。成果应包括不同模型的训练过程、模型评估结果以及模型对比分析，对应“四、项目任务说明”中的第 6、7 部分。你需要完成所有模型的训练，并使用合适的评价指标进行评估；如果选择回归任务，可以使用 MAE、RMSE、 R^2 等指标；如果选择分类任务，可以使用准确率、精确率、召回率、F1 值、混淆矩阵等指标。同时，你需要分析模型目前存在的问题，例如是否存在欠拟合、过拟合、类别不平衡、预测误差较大或特征解释不足等，并提出后续改进方向。本阶段的目标是确保你已经完成初步建模、结果评估与模型比较，能够根据评价结果判断模型表现。

六、项目汇报

- **汇报时间：6 月 2 日、6 月 4 日随堂汇报。**
- 汇报顺序：随机生成顺序，在第三周公布。
- 每位同学需进行项目展示 (ppt)，汇报时间为 5 分钟。
- 汇报内容应围绕项目的核心分析思路、关键方法、主要结果与结论展开。

- 汇报时应重点说明自己“为什么这样分析、如何建模、得到了什么结果、结果说明了什么”，而不是简单朗读 PPT 文字。
- PPT 重点呈现关键图表、模型结果、对比分析和结论性内容。
- PPT 中不建议展示代码。

七、项目成果提交

项目成果提交截止时间：6 月 5 日 23:59

1. 实践报告

- 内容应包含：实验过程、关键方法说明、结果展示与分析、问题与解决方法、实验总结
- 以分析与解释为主，不得仅堆砌代码或截图
- 建议命名：学号_姓名_大数据实践报告.docx

2. 代码文件

- 提交 .ipynb 或 .py 文件
- 代码须可运行，覆盖完整流程（数据处理、分析、建模、评估）
- 应包含必要注释

3. 运行证明视频

- 展示打开运行环境、执行代码、输出结果等关键过程
- 仅提供截图不视为有效证明

4. 汇报用的 PPT

- 内容应包括：问题背景、数据说明、关键分析结果、建模方法、主要结论
- 图表清晰，结构简洁

八、评分标准

评分维度	分值	评价指标
数据理解与预处理	20 分	能正确读取并合并数据（5 分）；完成缺失值、重复值、异常值检查并说明合理（8 分）；数据处理规范（如标准化、变量处理等）且有解释（7 分）

探索性数据分析 (EDA)	20 分	图表完整 (8 分) ; 图表规范清晰 (4 分) ; 能基于图表进行有效分析 (8 分)
任务设计与思路	10 分	明确任务目标 (4 分) ; 任务设计合理 (3 分) ; 方法选择与 EDA 结果有联系 (3 分)
建模与实现	25 分	建立基线模型 (6 分) ; 至少两种模型及比较 (12 分) ; 建模流程完整 (训练、预测、结果输出) (7 分)
模型评估与分析	15 分	使用合适评估指标 (5 分) ; 能够分析误差或误分类情况 (5 分) ; 模型比较有解释 (5 分)
实践报告质量	10 分	结构完整 (4 分) ; 分析与解释充分 (4 分) ; 表达规范清晰 (2 分)
PPT 与课堂汇报	10 分	PPT 结构清晰、内容完整 (5 分) ; 汇报表达清楚, 能解释思路与结论 (5 分)

最终成绩核算方法:

成绩构成	分项成绩	考核方式
实践 (100%)	期末成绩(70%)	汇报 (30%)
		项目报告 (70%)
	平时成绩(30%)	课堂参与 (20%)
		阶段任务 (80%)