

《大数据应用分析实践》项目报告

第一阶段成果报告

姓名：俞成儒 学号：202331060931

2026 年 5 月 14 日

目录

1 项目概述	3
2 数据集说明	3
2.1 数据规模概览	3
2.2 变量含义说明	3
3 数据预处理	4
3.1 缺失值与重复值处理	4
3.2 异常值识别与处理	4
3.3 标准化处理	5
3.4 数据集合并	6
4 探索性数据分析 (EDA)	6
4.1 整体分布特征分析	6
4.2 红白葡萄酒类别差异	7
4.3 质量相关性与变量间关系	8
4.4 基于机器学习的特征重要性的高级分析	12
5 任务设计	13
6 PCA 降维分析	13
6.1 分析过程	13
6.2 结果讨论	13
7 建模与实现	13
7.1 模型选择	13
7.2 特征使用	13
8 模型评估与结果分析	13
8.1 回归任务表现	13
8.2 分类任务表现	14
9 结果讨论	14
10 结论	14
11 问题与改进	14

1 项目概述

本项目基于经典的 Wine Quality dataset 数据集 [1] 展开，目标是借助数据分析方法，探索理化指标与质量之间的关系，并尝试建立模型进行预测或识别。该项目是一个完整的数据科学实践流程，包括过数据清洗、探索性分析、任务设计、建模与评估。全流程强调分析过程和结果解释。

本周完成数据集说明、数据预处理和探索性数据分析部分。

2 数据集说明

初始数据文件是winequality-red.csv和winequality-white.csv。在将两个数据文件合并后，获得winequality.csv，新增变量 type，表示葡萄酒种类，0 表示白葡萄酒，1 表示红葡萄酒。

2.1 数据规模概览

下表展示了本项目所使用的红、白葡萄酒数据集的样本分布情况。

表 1: Wine Quality 数据集规模统计

数据子集	样本数量	特征维度	目标变量
红葡萄酒 (Red Wine)	1599	11	Quality
白葡萄酒 (White Wine)	4898	11	Quality

2.2 变量含义说明

数据集包含 11 个理化特征以及合并时新增的类别变量，各变量的具体含义如表 2 所示。

表 2: 数据集理化指标与变量含义

变量名称	中文含义	简要说明
fixed acidity	固定酸度	葡萄酒中非挥发性酸的含量。
volatile acidity	挥发性酸度	主要是醋酸含量，过高会产生异味。
citric acid	柠檬酸	增添风味。
residual sugar	残余糖分	发酵后剩余糖分。
chlorides	氯化物	盐分含量。
free sulfur dioxide	游离二氧化硫	防止微生物生长和氧化。
total sulfur dioxide	总二氧化硫	浓度过高会影响感官表现。
density	密度	取决于酒精和糖分的百分比。
pH	pH 值	衡量酸碱度，通常在 3.0-4.0。
sulphates	硫酸盐	维持二氧化硫水平的添加剂。
alcohol	酒精含量	体积酒精度 (% vol)。
type	种类	红 (0) 或白 (1) 葡萄酒。
quality	质量评分	目标变量 (0-10)。

3 数据预处理

3.1 缺失值与重复值处理

通过程序检查发现，原始数据集较为完整，不存在缺失值。对于重复值，选择予以保留，因为葡萄酒理化指标可能存在天然相同的样本。

表 3: Wine Quality 数据集缺失重复统计

数据子集	缺失值数量	重复值数量
红葡萄酒	0	240
白葡萄酒	0	937

3.2 异常值识别与处理

首先，本文利用箱线图和 Z-Score 方法进行了初步的异常值识别。当阈值设定为 3 时，Z-Score 方法在红葡萄酒数据集中检出 192 个异常值，在白葡萄酒数据集中检出 475 个异常值。观察箱线图（图 1）可知，大多数异常值由二氧化硫属性导致，而其他属性的分布则相对符合 Z-Score 的正态分布假设。由于这种基于单一维度的常规方法难以有

效捕捉数据在属性结构上的不合理性，本文进一步引入了先进的 TabPFN 模型 [2] 来执行更深层次的异常检测。




图 1: 红白葡萄酒数据集异常识别的箱线图

在通过 TabPFN 模型检出数据集中的结构性异常点后，本研究决定将其从数据集中剔除，主要基于以下两点考虑：

首先，本章的后续核心任务之一是开展无监督聚类分析。大多数主流聚类算法高度依赖于特征空间中的距离度量，对极端偏离群体分布的结构性异常点极其敏感。若予以保留，这些异常样本将严重偏移聚类中心，破坏簇划分的有效性。

其次，在葡萄酒质量回归任务中，尽管部分非线性模型对异常点具有一定包容度，但 TabPFN 识别出的异常代表了属性间的逻辑冲突，例如极高的含糖量与极低的密度的不合理组合，这极有可能源于数据录入或测量误差。为保证后续回归模型学习到的是真实、普遍的理化属性与质量间的映射规律，剔除这些噪声干扰是必要的预处理步骤。

因此，红葡萄酒数据集剔除 19 个样本，最终保留了 1580 个样本，白葡萄酒数据集剔除 49 个样本，保留了 4849 个样本。剔除异常点为后续的模型构建提供了高质量的数据基础。

3.3 标准化处理

由于数据集中各特征变量的量纲差异较大，为了消除量纲对模型性能的影响，我们采用最小-最大归一化（Min-Max Scaling）对数据进行处理，将所有数值线性映射到 $[0, 1]$ 区间内。具体的计算公式如下：

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

其中， x_i 表示某个特征的原始观测值， $x_{\min}$ 和 $x_{\max}$ 分别表示该特征在数据集的最小值和最大值， x'_i 为处理后映射到 $[0, 1]$ 之间的新值。

目标变量 *quality* 不进行标准化。

3.4 数据集合并

最后，本文对经过异常值剔除与标准化处理的红、白葡萄酒数据集进行了合并，并新增了类别特征 (type)，其中 0 代表红葡萄酒，1 代表白葡萄酒。合并后的数据集共包含 6429 个样本、12 个特征维度，此外还包含 1166 个重复样本。

针对合并后的数据集，本文绘制了质量评分 (Quality) 的分布柱状图 (如图 2 所示)。可以观察到，目标变量呈现出明显的类别不平衡现象：样本评分主要集中在 5、6、7 三个档位，而极端评分 (最小值为 3，最大值为 9) 的样本数量极少。




图 2: 合并数据集的 Quality 属性分布柱状图

4 探索性数据分析 (EDA)

本章综合各种理化指标，通过统计分析与可视化方法，从整体分布特征、红白葡萄酒差异、变量相关性以及基于机器学习的特征重要性四个维度展开了探索性数据分析分析。

4.1 整体分布特征分析

观察图3和图4，对所有理化指标的集中趋势、离散程度和偏度进行分析发现，大部分变量呈现右偏分布 (正偏度)。其中，氯化物 (Chlorides, 偏度: 5.40, 峰度: 50.90) 和残余糖分 (Residual Sugar, 偏度: 1.44) 表现出极端的右侧长尾现象，这表明在极少数葡萄酒样本中存在极高浓度的异常值。相比之下，密度 (Density) 和 pH 值的分布偏

度极低，更接近标准的正态钟形曲线。从集中趋势来看，酒精浓度（Alcohol）的均值为 10.49，标准差为 1.19；而总二氧化硫（Total Sulfur Dioxide）分布极广，均值为 115.74，标准差高达 56.52。具体见表4。




图 3: 数据分布直方图

4.2 红白葡萄酒类别差异

利用 Mann-Whitney U 非参数检验方法对比红白两种葡萄酒的属性差异，得到图5，表5。结果显示除了酒精浓度外，几乎所有理化变量在两种类型的葡萄酒之间均表现出极其显著的统计学差异 ($p < 0.05$)。

- **差异显著变量：**区分红白葡萄酒最显著的特征是总二氧化硫。白葡萄酒中的总二氧化硫含量（中位数 134.0）远超红葡萄酒（中位数 38.0），这与白葡萄酒工艺中通




图 4: 数据整体箱线图

常需要更多二氧化硫以防腐保鲜的现实逻辑一致。同时，白葡萄酒显著更甜（残余糖分中位数 5.2 对 2.2）且游离二氧化硫更高；而红葡萄酒则含有更高的挥发性酸度（中位数 0.52 对 0.26）以及几乎翻倍的氯化物（中位数 0.079 对 0.043）。

- **无显著差异变量：**红白葡萄酒的酒精浓度无统计学显著差异（ $p = 0.1818$ ），两者的中位数均在 10.2% 至 10.4% 之间。

4.3 质量相关性 with 变量间关系

在质量差异方面，属性相关性热力图6和箱线图7趋势清晰揭示了关键理化指标对葡萄酒评分的影响机制：

表 4: 葡萄酒核心理化指标整体分布关键统计量

理化指标	均值	标准差	偏度	峰度
酒精浓度 (Alcohol)	10.49	1.19	0.57	-0.53
残余糖分 (Residual Sugar)	5.44	4.76	1.44	4.36
氯化物 (Chlorides)	0.056	0.035	5.40	50.90
总二氧化硫 (Total SO2)	115.74	56.52	-0.00	-0.37
密度 (Density)	0.994	0.003	0.50	6.61
pH 值	3.22	0.16	0.39	0.37




图 5: 红白葡萄酒对比小提琴图

表 5: 红白葡萄酒核心理化属性差异检验结果 (Mann-Whitney U Test)

理化指标	红葡萄酒 (中位数)	白葡萄酒 (中位数)	p 值	显著性 ($p < 0.05$)
总二氧化硫	38.00	134.00	< 0.001	显著 (True)
挥发性酸度	0.52	0.26	< 0.001	显著 (True)
残余糖分	2.20	5.20	< 0.001	显著 (True)
氯化物	0.079	0.043	< 0.001	显著 (True)
酒精浓度	10.20	10.40	0.1818	不显著 (False)




图 6: 相关性热力图

- **质量相关性：**酒精浓度与质量评分呈现最强的正相关关系（相关系数 $+0.44$ ），说明高品质葡萄酒往往酒精度更高。密度与质量呈现最强负相关（ -0.31 ），挥发性酸度同样对质量有明显负面影响（ -0.27 ），表明降低产生醋味的挥发性酸度对提升感官评分至关重要。
- **变量内生相关性：**密度与残余糖分具有强正相关性（ $+0.55$ ），符合糖分溶解增加液体密度的物理规律；相对地，密度与酒精浓度呈现强负相关（ -0.69 ）。此外，如预期一致，总二氧化硫与游离二氧化硫之间呈高度正相关（ $+0.72$ ）。




图 7: 不同质量等级的箱线图

4.4 基于机器学习的特征重要性与高级分析

为进一步验证变量间的多维结构关系并突破常规统计局限，本章引入随机森林 (Random Forest) 算法 [3] 进行特征重要性排序。结果如图8，表6。

发现酒精浓度 (0.124) 是预测葡萄酒质量的最核心单一变量，紧随其后的是密度 (0.103) 和挥发性酸度 (0.100)。这一结果完美印证了相关性分析的结论：若需干预或预测葡萄酒品质，控制酒精含量、严控挥发性酸度以及平衡密度是三个最有效的化学干预抓手。




图 8: 随机森林特征重要性条形图

表 6: 基于随机森林算法预测葡萄酒质量的特征重要性排序 (Top 5)

特征名称	Gini 重要性得分
酒精浓度 (Alcohol)	0.1235
密度 (Density)	0.1032
挥发性酸度 (Volatile Acidity)	0.1005
总二氧化硫 (Total Sulfur Dioxide)	0.0917
氯化物 (Chlorides)	0.0879

参考文献

- [1] Paulo Cortez, António Cerdeira, Fernando Almeida, Telmo Matos, and José Reis. Modeling wine preferences by data mining from physicochemical properties. *Decision support systems*, 47(4):547–553, 2009.
- [2] Patryk Marszałek, Tomasz Kuśmierczyk, and Marek Śmieja. Tactic for navigating the unknown: Tabular anomaly detection via in-context inference. *arXiv preprint arXiv:2603.14171*, 2026.
- [3] Steven J Rigatti. Random forest. *Journal of insurance medicine*, 47(1):31–39, 2017.